

7.3 Optimering med bibetingelser

- ▶ I MAT1110 behandles Lagranges metode for å finne maksimum og/eller minimum av funksjoner av flere variable under gitte bibetingelser.
- ▶ Vi skal se på en alternativ måte å gjøre dette på for kvadratiske former under nokså spesielle bibetingelser.
- ▶ Hovedpoenget er at dette gir en interessant tolkning av hva egenverdiene til en symmetrisk matrise betyr.
- ▶ Til slutt ser vi på *singulærverdiene* til en matrise.

Teorem 6. La A være en symmetrisk $n \times n$ matrise.


Betrakt den kvadratiske formen $Q(\mathbf{x}) = \mathbf{x}^T A \mathbf{x}$ på enhetssfæren

$$S = \{\mathbf{x} \in \mathbb{R}^n \mid \|\mathbf{x}\| = 1\}.$$

Da har Q et (globalt) maksimum M og et (globalt) minimum m på S .

- ▶ M er A 's største egenverdi, og $Q(\mathbf{x}) = M$ når \mathbf{x} er en enhetsegenvektor tilhørende egenverdien M .
- ▶ m er A 's minste egenverdi, og $Q(\mathbf{x}) = m$ når \mathbf{x} er en enhetsegenvektor tilhørende egenverdien m .

En illustrasjon med $Q(\mathbf{x}) = 5x_1^2 - 4x_1x_2 + 5x_2^2$. Her er $M = 7$ og $m = 3$.



Hva med de andre egenverdiene til en symmetrisk matrise A ?

Teorem 7. La A være en symmetrisk $n \times n$ matrise (der $n \geq 2$) og betrakt

$$Q(\mathbf{x}) = \mathbf{x}^T A \mathbf{x}.$$

Skriv egenverdiene til A i avtagende rekkefølge:

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n$$

så $M = \lambda_1$ og $m = \lambda_n$ i notasjonen fra Teorem 6.

La $\{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n\}$ være en o.n.b. for \mathbb{R}^n som består av tilhørende egenvektorer (så $A \mathbf{u}_j = \lambda_j \mathbf{u}_j$ for $j = 1, \dots, n$).

Sett $S_2 = \{\mathbf{x} \in S \mid \mathbf{x} \text{ er ortogonal på } \mathbf{u}_1\}$, m.a.o.

$$S_2 = \{\mathbf{x} \in S \mid \mathbf{x}^T \mathbf{u}_1 = 0\}.$$

Da har Q et (globalt) maksimum på S_2 , nemlig λ_2 , som oppnåes når $\mathbf{x} = \pm \mathbf{u}_2$.

Behold de samme antagelsene som i Teorem 7, og anta at $n \geq 3$.
Vi kan da betrakte

$$S_3 = \left\{ \mathbf{x} \in S \mid \mathbf{x}^T \mathbf{u}_1 = \mathbf{x}^T \mathbf{u}_2 = 0 \right\},$$

eller mer generelt, for $k \in \{3, \dots, n\}$,

$$S_k = \left\{ \mathbf{x} \in S \mid \mathbf{x}^T \mathbf{u}_1 = \dots = \mathbf{x}^T \mathbf{u}_{k-1} = 0 \right\}.$$

Da har vi at Q et (globalt) maksimum på S_k . Dette maksimumet er egenverdien λ_k og det oppnåes når $\mathbf{x} = \pm \mathbf{u}_k$.

Dette er [Teorem 8](#) i boka.

Preludium til singulærverdi dekomposisjonen av en matrise

La A være en $m \times n$ matrise og betrakt $S = \{\mathbf{x} \in \mathbb{R}^n \mid \|\mathbf{x}\| = 1\}$.

Hva er maksimum av funksjonen $f(\mathbf{x}) := \|A\mathbf{x}\|$ på S ?

Dette maksimumet er en viktig størrelse knyttet til A , som kalles *operatornormen til A* .

Funksjonen $f(\mathbf{x}) = \|A\mathbf{x}\|$ er ikke en kvadratisk form, så vi kan ikke bruke Teorem 6 på $f(\mathbf{x})$. Men vi har at

$$\|A\mathbf{x}\|^2 = (A\mathbf{x})^T A\mathbf{x} = \mathbf{x}^T A^T A \mathbf{x}$$

for alle $\mathbf{x} \in \mathbb{R}^n$.

Så $K(\mathbf{x}) := f(\mathbf{x})^2 = \|A\mathbf{x}\|^2$ er en kvadratisk form på \mathbb{R}^n assosiert med den *symmetriske* $n \times n$ matrisen $A^T A$.

Teorem 6, anvendt på K , gir at

- ▶ Maksimum av $\|A\mathbf{x}\|^2$ på S eksisterer og er lik $A^T A$'s største egenverdi.
- ▶ Dette maksimumet oppnåes på enhetsegenvektorene til $A^T A$ tilhørende denne egenverdien.

La λ_1 betegne den største egenverdien til $A^T A$ og la \mathbf{v}_1 være en tilhørende enhetsegenvektor.

Sett $\sigma_1 = \sqrt{\lambda_1}$.

Siden $\|A\mathbf{x}\| = \sqrt{\|A\mathbf{x}\|^2} = \sqrt{K(\mathbf{x})}$, får vi at

- ▶ Maksimum av $\|A\mathbf{x}\|$ på S eksisterer og er lik σ_1 .
- ▶ Dette maksimumet oppnåes på $\pm \mathbf{v}_1$.

Dette betyr at $\boxed{\text{operatornormen til } A \text{ er lik } \sigma_1}$.

7.4 Singulærverdi dekomposisjonen

- ▶ Singulærverdi dekomposisjon til en rektangulær matrise A er en av de viktigste faktoriseringene av A (dvs. A skrives som et produkt av matriser).
- ▶ Den inneholder nyttig informasjon om A og de fundamentale underrommene knyttet til A , f.eks. nullrommet.
- ▶ Den brukes i mange praktiske anvendelser, men er også av stor betydning i teoretiske studier og ved numeriske betraktninger.

La A være en (rekta)ngulær $m \times n$ matrise. Da er $A^T A$ en reell *symmetrisk* $n \times n$ matrise, så den kan ortogonal diagonaliseres:

La $\mathbf{v}_1, \dots, \mathbf{v}_n$ være en ortonormal basis for \mathbb{R}^n som består av egenvektorer for $A^T A$ og la $\lambda_1, \dots, \lambda_n$ være de tilhørende egenverdiene til $A^T A$.

- ▶ For hver $1 \leq i \leq n$ har vi at $\lambda_i = \|A\mathbf{v}_i\|^2$.
- ▶ Dette medfører at *alle egenverdiene til $A^T A$ er ikke-negative*. Så matrisen $A^T A$ er **positiv semidefinit**.

Ved å bytte om på rekkefølgen om nødvendig, kan vi anta at

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n \geq 0$$

Singulærverdiene til A , $\sigma_1, \dots, \sigma_n$, defineres ved

$$\sigma_i = \sqrt{\lambda_i}, \quad i = 1, \dots, n.$$

Vi har da at $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq 0$ og

$$\sigma_i = \sqrt{\lambda_i} = \sqrt{\|A\mathbf{v}_i\|^2} = \|A\mathbf{v}_i\|, \quad i = 1, \dots, n$$

Teorem 9. La A være en $m \times n$ matrise ($A \neq O$).

La $\{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ være en o.n.b. for \mathbb{R}^n av egenvektorer for $A^T A$ med tilhørende egenverdier $\lambda_1, \dots, \lambda_n$ ordnet i avtagende rekkefølge.

La $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ angi alle singulærverdiene til A som ikke er null.

Da er $\{A\mathbf{v}_1, \dots, A\mathbf{v}_r\}$ en ortogonal basis for $\text{Col } A$ og $\text{rang } A = r$.

Videre, hvis $r < n$, så er $A\mathbf{v}_{r+1} = \dots = A\mathbf{v}_n = \mathbf{0}$.

Teorem 10 (Singulærverdi dekomposisjonen)

La A være en $m \times n$ reell matrise, $A \neq O$.

La $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ angi de singulærverdiene til A som ikke er null (så $r = \text{rank } A$). Da kan A faktoriseres på formen

$$A = U \Sigma V^T$$

der U er en $m \times m$ ortogonal matrise, V er en $n \times n$ ortogonal matrise, mens $\Sigma = \begin{bmatrix} D & O \\ O & O \end{bmatrix}$ er $m \times n$ "diagonal" matrisen der $D = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$.

- ▶ Faktoriseringen ovenfor kalles en singulærverdi dekomposisjon (eller SVD) til A .
- ▶ Merk at matrisene U og V er ikke entydig bestemte av A , så det finnes flere SVD'er for A .
- ▶ Kolonnene til U kalles ofte venstre singulære vektorer for A , mens kolonnene til V kalles høyre singulære vektorer for A .

Beregning av SVD for hånd.

1. [Finn V] Beregn $A^T A$ og ortogonal diagonaliser denne.
 - ▶ La $\{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ være en o.n.b. for \mathbb{R}^n av egenvektorer for $A^T A$ tilhørende egenverdiene $\lambda_1, \dots, \lambda_n$, ordnet i avtagende rekkefølge.
 - ▶ Sett $V = [\mathbf{v}_1 \ \dots \ \mathbf{v}_n]$. Da er V ortogonal.
2. [Finn Σ] Sett $\sigma_j = \sqrt{\lambda_j}$ for $j = 1, \dots, n$.
 - ▶ Da er σ_j -ene singulærverdiene til A .
 - ▶ Sett $D = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$, der $\sigma_1, \sigma_2, \dots, \sigma_r$ angir alle singulærverdiene som ikke er null (så $\text{rank } A = r$).
 - ▶ Dann $m \times n$ "diagonalmatrisen" Σ basert på D .
3. [Finn U] Beregn $\mathbf{u}_j = \frac{1}{\sigma_j} A \mathbf{v}_j$ for $j = 1, \dots, r$.
 - ▶ Mengden $\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$ er da ortonormal.
 - ▶ Dersom $r < m$: utvid $\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$ til en o.n.b. $\{\mathbf{u}_1, \dots, \mathbf{u}_m\}$ for \mathbb{R}^m .
 - ▶ Dann den ortogonale matrisen $U = [\mathbf{u}_1 \ \dots \ \mathbf{u}_m]$.
4. Da er $A = U \Sigma V^T$ en SVD for A .

SVD'en til A inneholder mye informasjon. F.eks. har vi at :

- $\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$ er en o.n. basis for $\text{Col } A$.
- $\{\mathbf{u}_{r+1}, \dots, \mathbf{u}_m\}$ er en o.n. basis for $\text{Nul } A^T$ (når $r < m$).
- $\{\mathbf{v}_1, \dots, \mathbf{v}_r\}$ er en o.n. basis for $\text{Row } A$.
- $\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_n\}$ er en o.n. basis for $\text{Nul } A$ (når $r < n$).

Merk: Punkt b. kan utnyttes til å konstruere $\{\mathbf{u}_{r+1}, \dots, \mathbf{u}_m\}$.

Invertibel Matrise Teoremet - Siste tillegg !

La A være en $n \times n$ matrise. Følgende er ekvivalent :

- ▶ A er invertibel.
- ▶ $(\text{Col } A)^\perp = \{\mathbf{0}\}$.
- ▶ $(\text{Nul } A)^\perp = \mathbb{R}^n$.
- ▶ $\text{Row } A = \mathbb{R}^n$.
- ▶ A har n singulærverdier som ikke er null.

Kort om kondisjonstallet til en invertibel matrise

La A være en invertibel matrise og betrakt et system $A\mathbf{x} = \mathbf{b}$.

Vi vet at systemet har da en entydig løsning. I noen tilfeller vil avrundingsfeil i beregningene føre til at løsningen man beregner er ganske forskjellig fra den entydige løsningen man ønsker å finne.

Når er A av en slik type ? (Man sier at A er **ille-kondisjonert**).

La $A = U\Sigma V^T$ være en SVD til A . Siden U og V er ortogonale matriser vil årsaken til problemet ligge i Σ .

Man kan da innføre **kondisjonstallet til A** ved
$$\text{cond } A = \frac{\sigma_1}{\sigma_n}.$$

Her er σ_1 er den største singulære verdien mens σ_n er den minste.

Det kan vises at et høyt kondisjonstall for A vil som regel føre til numerisk ustabilitet.

Redusert SVD og pseudoinvers

La $A = U\Sigma V^T$ være en SVD til en matrise A med rang r .

Utrekning gir

$$A = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^T + \cdots + \sigma_r \mathbf{u}_r \mathbf{v}_r^T.$$

Dette kan omskrives som

$$A = U_r D V_r^T$$

der $U_r = [\mathbf{u}_1 \ \cdots \ \mathbf{u}_r]$, $D = \text{diag}(\sigma_1, \dots, \sigma_r)$, $V_r = [\mathbf{v}_1 \ \cdots \ \mathbf{v}_r]$.

En slik faktorisering av A kalles en *redusert SVD til A* .

Siden D er invertibel kan vi danne matrisen

$$A^+ = V_r D^{-1} U_r^T$$

Man kaller A^+ for *pseudoinversen (eller Moore-Penrose inversen) til A* .

Hva kan den pseudoinverse matrisen A^+ brukes til?

Betrakt et (inkonsistent) system $A\mathbf{x} = \mathbf{b}$. Da har vi at

$\hat{\mathbf{x}} := A^+ \mathbf{b}$ er en minstekvadraters løsning av $A\mathbf{x} = \mathbf{b}$.

Poenget er at da er $A\hat{\mathbf{x}} = U_r U_r^T \mathbf{b} = \text{Proj}_{\text{Col}_A}(\mathbf{b})$

og vi har sett tidligere at dette betyr at $\hat{\mathbf{x}}$ er en minstekvadraters løsning av systemet.

Merk: Det kan vises at $\hat{\mathbf{x}} = A^+ \mathbf{b}$ har **minst avstand til origo** blant alle minstekvadraters løsninger til systemet.

Det er også verdt å poengtere at her antaes det *ikke* at A har lineært uavhengige kolonner; likevel angis det en formel for en minstekvadraters løsning, og det er ofte nyttig.

Lyst på mer lineær algebra ?!

Det fins flere tilbud!

- ▶ MAT3100 Lineær optimering (vår)
- ▶ MAT-IN4130 - Numerisk lineær algebra (høst)
- ▶ MAT3400/4400 - Lineær analyse med anvendelser (vår) –
NB: bør ha tatt først MAT2400 - Reell analyse (vår)

Teorem 3

La A være en $n \times n$ matrise ($n \geq 2$)

og betrakt $Q(x) = x^T A x$. La egenverdierne til A være $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$, så,

\vdots
 \vdots

Opgave 7.3.6 a) Finn max val av

$$Q(x) = 3x_1^2 + 2x_2^2 + 8x_1x_2$$

$$A = \begin{bmatrix} 3 & 4 \\ 4 & 2 \end{bmatrix} \Rightarrow Q(x) = x^T A x$$

$$\begin{aligned} \text{a)} \quad \text{Ved teorem 6 er } \max \{ Q(x) : x^T x = 1 \} \\ = \lambda_1 = 11 \end{aligned}$$

b) Kan velge u som enhets egenvektor

tilhørende $\lambda_1 = 11$. Regningsrikingen gir

(1, 2) en egenvektor for λ_1 , så $u = \frac{1}{\sqrt{10}} \begin{bmatrix} 1 \\ 2 \end{bmatrix}$
oppå mots verdi.

c) Ved Teorem 3 er maksimum av Q når
 $x^T x = 1$ og $x^T u = 0$ lih ... - - - - -

Preludium i til singuler verdi dekomposisjonen til en matrise.



La A være en $m \times n$ matrise og betrakt

$$S = \{ x \in \mathbb{R}^n : \|x\| = 1 \} \quad (x^T x = 1)$$

Hva er maksimum av funksjonen
 $f(x) = \|Ax\|$ på S ?

$$f: \mathbb{R} \rightarrow \mathbb{R}$$

$$A: 2 \times 2$$



Operatoromet, hvor mye har vektoren på $(x \rightarrow Ax)$ lengden.

Funksjonen $f(x) = \|Ax\|$ er ikke en kvadratisk form, så vi kan ikke bruke teoren 6 på $f(x)$.

Men vi har at

$$\|Ax\|^2 = (x^T A^T A)x = x^T A^T A x \text{ for alle } x \in \mathbb{R}^n$$

Så $K(x) = f(x)^2 = \|Ax\|^2$ så det er en kvadratisk form på \mathbb{R}^n assosiert med den symmetriske $n \times n$ matrisen $A^T A$ (Kash: $(A^T A)^T = A^T (A^T)^T = A^T A$)

Theorem 6, så anvendt på K , gir at

- Max av $\|Ax\|^2$ døt eksisterer og er lik $A^T A$'s største eigenverdi
- Dette max oppnås for enhets eigenvektoren til $A^T A$ tilhørende denne eigenverdien

La λ_1 være den største eigenverdien til $A^T A$ og la v_{11} være en tilhørende eigenvektor.

Satt $\sigma_i = \sqrt{\lambda_i}$

Siden $\|Ax\| = \sqrt{\|\lambda x\|^2} = \sqrt{\lambda_{ii}}$, får vi at

- max av $\|Ax\|$ på s effekter, er og ur lik σ_i

- Dette matbraket oppnås på \hat{v}_i

Dette betyr at operatorenver til A er lik σ_i