

STK1100 våren 2018

Poissonfordelingen

Svarer til avsnitt 3.7 i læreboka

Ørnulf Borgan
Matematisk institutt
Universitetet i Oslo

1

Poissonfordelingen er oppkalt etter den franske fysikeren og matematikeren Siméon Denis Poisson (1781-1840)



Poisson viste at hvis $n \rightarrow \infty$ og $p \rightarrow 0$ på en slik måte at $np \rightarrow \lambda > 0$ så vil

$$\binom{n}{x} p^x (1-p)^{n-x} \rightarrow \frac{\lambda^x}{x!} e^{-\lambda}$$

Eks: $x \sim \text{Bin}(n, p)$
 $p = p_n$
Dette betyr at her n er stor og p er liten, så vil $\binom{n}{x} p^x (1-p)^{n-x} \approx \frac{\lambda^x}{x!} e^{-\lambda}$
 $\lambda = np$

Poisson brukte dette til å finne en tilnærming til den binomiske fordelingen når n er stor og p er liten

2

Seinere fant en ut at en kunne bruke den grensen Poisson fant som punktsannsynligheten til en stokastisk variabel

Vi sier at en stokastisk variabel X er **Poissonfordelt** med parameter λ hvis den har punktsannsynlighet

$$p(x; \lambda) = \frac{\lambda^x}{x!} e^{-\lambda} \quad \text{for } x = 0, 1, 2, \dots$$

Merk at $\sum_{x=0}^{\infty} p(x; \lambda) = 1$ slik det skal være for en punktsannsynlighet

3

Poissonfordeling med MATLAB

Punktsannsynlighet:

$$p(x; \lambda) = P(X = x) = \frac{\lambda^x}{x!} e^{-\lambda}$$

MATLAB: `poisspdf(x, λ)`

Kumulativ fordeling:

$$F(x; \lambda) = P(X \leq x) = \sum_{y=0}^x \frac{\lambda^y}{y!} e^{-\lambda}$$

MATLAB: `poisscdf(x, λ)`

Tabell A.2 bak i boka gir $F(x; \lambda)$ for noen verdier av λ

Vi vil ikke bry oss om disse tabellene

4

Anten at $np = \lambda$

Har at x er gitt naturlig tale

$$\binom{n}{x} p^x (1-p)^{n-x} = \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x}$$

$$= \frac{n(n-1)(n-2)\dots(n-x+1)}{n \cdot n \cdot n \dots n} \frac{(np)^x}{x!} (1-p)^n \frac{1}{(1-p)^x} \quad p = \frac{\lambda}{n}$$

$$= \underbrace{\frac{n(n-1)\dots(n-x+1)}{n \cdot n \dots n}}_{n \rightarrow \infty \atop 1} \frac{\lambda^x}{x!} \underbrace{\left(\frac{1-\lambda}{n}\right)^n}_{e^{-\lambda} \text{ } n \rightarrow \infty} \frac{1}{\left(1-\frac{\lambda}{n}\right)^x}$$

$$\rightarrow \frac{\lambda^x}{x!} e^{-\lambda} \quad n \rightarrow \infty$$

Sammenligning av binomisk og Poisson

Vi vil sammenligne de binomiske fordelinger med $n = 20, p = 0.10$ og $n = 200, p = 0.01$ med Poissonfordelingen med $\lambda = 2$

MATLAB:

```
x=(0:10)'
[x binopdf(x,20,0.1) binopdf(x,200,0.01) poisspdf(x,2)]
```

Resultatet er gitt på neste slide

5

x	$b(x;20,0.10)$	$b(x;200,0.01)$	$p(x;2)$
0	0.1216	0.1340	0.1353
1	0.2702	0.2707	0.2707
2	0.2852	0.2720	0.2707
3	0.1901	0.1814	0.1804
4	0.0898	0.0902	0.0902
5	0.0319	0.0357	0.0361
6	0.0089	0.0117	0.0120
7	0.0020	0.0033	0.0034
8	0.0004	0.0008	0.0009
9	0.0001	0.0002	0.0002

Vi kan ofte bruke Poissonfordelingen til å beskrive forekomsten av «sjeldne begivenheter» :

- Antall tvillingfødsler i løpet av ett år på et sykehus
- Antall krefttilfeller i løpet av ett år i en kommune
- Antall ulykker i løpet av én måned på en byggeplass

Vi vil se på et konkret eksempel om litt, men først vil vi finne forventning og varians for Poissonfordelingen

7

Forventning og varians

Momentgenererende funksjon:

$$\begin{aligned} M_X(t) &= E(e^{tX}) = \sum_{x=0}^{\infty} e^{tx} \cdot p(x) = \sum_{x=0}^{\infty} e^{tx} \frac{\lambda^x}{x!} e^{-\lambda} \\ &= e^{-\lambda} \sum_{x=0}^{\infty} \frac{(e^t \lambda)^x}{x!} = e^{-\lambda} e^{\lambda e^t} = e^{\lambda(e^t - 1)} \end{aligned}$$

Kumulatngenererende funksjon

$$R_X(t) = \ln \{ M_X(t) \} = \lambda(e^t - 1)$$

Forventning

$$\mu = E(X) = R'_X(0) = \lambda$$

Varians:

$$\sigma^2 = V(X) = R''_X(0) = \lambda$$

8

Eksempel:

Forekomst av anencefali i Edinburgh 1956-66

Anencefali er en alvorlig defekt hos fosteret som gjør at hjernen ikke utvikler seg som den skal. Antall barn født med anencefali i Edinburgh i de 132 månedene fra 1955 til 1956 er gitt i tabellen:

# anencefali	0	1	2	3	4	5	6	7	8	9+
# måneder	18	42	34	18	11	6	0	2	1	0

Kan dataene beskrives med Poissonfordelingen?

Her er gjennomsnittlig x -verdi er ca. lik $E(x)$
Antall tilfeller er $18 \cdot 0 + 42 \cdot 1 + 34 \cdot 2 + \dots + 1 \cdot 9 = 260$

$$\frac{260}{132} = 1.97$$

La X være antall tilfeller av anencefali i en måned

Hvis X er Poissonfordelt har vi at

$$P(X = x) = p(x; \lambda) = \frac{\lambda^x}{x!} e^{-\lambda}$$

$132 \cdot P(x; 1.97)$
Mottak
Poisson($\lambda=1.97$)

Vi ser på $n = 132$ måneder

Forventet antall måneder med x tilfeller er $n \cdot p(x; \lambda)$

For λ kan vi bruke gjennomsnittlig antall tilfeller per måned som er 1.97


# tilfeller	0	1	2	3	4	5	6	7	8
# observert	18	42	34	18	11	6	0	2	1
# forventet	18.4	36.2	35.7	23.5	11.6	4.5	1.4	0.4	0.1

Poissonfordeling passer bra

10

Poisson prosessen


Vi observeret begivenheter (markert med x) som hender over tid:



Vi antar at:

- sannsynligheten for at det inntreffer én begivenhet i et intervall av lengde Δt er $\alpha \Delta t + o(\Delta t) \sim \frac{o(\Delta t)}{\Delta t} \rightarrow 0$ som Δt sår forke
høst 0
- sannsynligheten for at det inntreffer mere enn én begivenhet i et intervall av lengde Δt er $o(\Delta t)$
- antall begivenheter i et intervall er uavhengig av hvor mange begivenheter som har skjedd tidligere

11



La $P_k(t)$ være sannsynligheten for at det inntreffer k begivenheter i et intervall av lengde t


$$\text{Da har vi at } P_k(t) = \frac{(\alpha t)^k}{k!} e^{-\alpha t}$$

Antall begivenheter i et intervall av lengde t $\frac{E(x)}{t} = \alpha$
er Poisson fordelt med parameter $\lambda = \alpha t$ raten til prosessen

Merk at α er forventet antall begivenheter per tidsenhet

α er raten til Poissonprosessen

12



Der er n dele

Hver delinterval har længde $\Delta t = \frac{t}{n}$

Ser fra delinterval om begivenheden ~~at~~

$$p = \alpha \Delta t = \alpha \frac{t}{n}$$

Uafhængighed fra interval til interval


Dermed (tilnærmelse) $x = \text{antal begivenheder} \sim \text{Bin}(n, p)$

n er stor og p er lille:

Derfor (tilnærmelse) $x \sim \text{Poisson}(\lambda)$ der $\lambda = np = \alpha t$

Min tilfeldig er altså trefft i et område Poisson fordelt med $\lambda = 0.93$

Vi kan også se på punkter i planet:



Anta at:

- forventet antall punkter per arealenhet er α
- det er ingen sammenfallende punkter
- antall punkter i disjunkte områder er uavhengige

Da har vi en **Poissonprosess** i planet

Dette er en modell for punkter som er «tilfeldig fordelt»

La X være antall punkter i et område R med areal $a(R)$

Da er X Poissonfordelt med parameter $\lambda = \alpha \cdot a(R)$

13

Eksempel:

Bombetreff av tyske V-1 raketter i Syd-London

Ser på antall treff av V-1 bomber i 576 små områder i Syd-London (**0.25 km²** hver) fra juni 1944 til mars 1945

# treff	0	1	2	3	4	5+
# observert	229	221	93	35	7	1
# forventet	226.7	211.4	98.5	30.6	7.1	1.6

$$P(X=x) = \frac{e^{-\lambda} \lambda^x}{x!}$$

Poissonfordelingen passer bra

14

Case studie: Krefttilfeller i Sømna



Dagbladet 10. januar 1993

15

POLITIKERE ER SKREMT

Krever Stortings-orientering

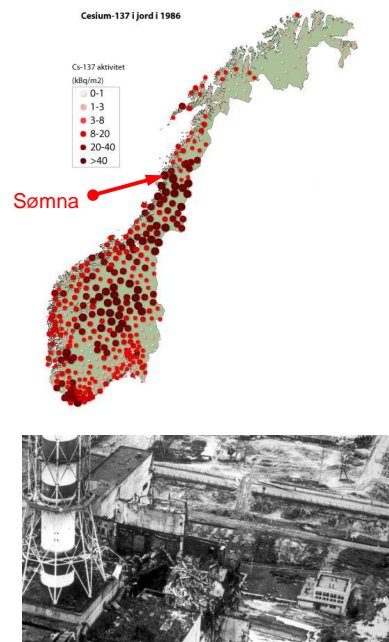
om kreftteoriene i Sømna

– Skremmende. Slik reagerer politikere Dagbladet har snakket med på reportasjen fra Sømna om frykten for kreftøkning som følge av Tsjernobyl.

Dagbladet 11. januar 1993

16

- Det ble observert tre tilfeller av hjernesvulst i Sømna kommune i 1992
- Det var uvanlig mange i en så liten kommune
- Saken vakte stor oppsikt i media og blant politikere.
- Ble sett i sammenheng med Tsjernobyl ulykken 26. april 1986



Etter Kreftregisterets statistikk vil en for en kommune av Sømna størrelse og befolknings-sammensetning i gjennomsnitt observere ett tilfelle av hjernesvulst hvert sjette år *hvis* kreft risikoen er som i resten av landet

Mer presist: Hvis kreft risikoen i Sømna var som ellers i landet, vil antall tilfeller av hjernesvulst i løpet av ett år være Poisson fordelt med $\lambda = 0.16$

Det gir: $P(\text{minst 3 tilfeller av hjernesvulst})$

$$= \sum_{k=3}^{\infty} \frac{0.16^k}{k!} e^{-0.16} = 0.0006$$

Det som skjedde i Sømna var svært usannsynlig hvis kommunen hadde samme kreft risiko som landet forøvrig

18

Tror at det skyldes ren tilfeldighet

— Tilfellet Sømna ser foreløpig ut som en ren tilfeldighet, sier Frøydis Langmark, Kreftregisterets leder.

I 1992 ble det registrert tre tilfeller av hjernesvulst i Sømna kommune i på Helgeland. Det normale i tidligere år har vært null til ett tilfelle. Hittil i år er det ikke registrert noen tilfeller.

Leder av Kreftregisteret, Frøydis Langmark, bruker uttrykket «cluster», eller opphopning om det som er skjedd. Hun sier dette er et ikke uvanlig fenomen, og at man sjelden finner spesielle grunner til at slikt skjer. Men Kreftregisteret vil likevel fortsette med å undersøke saken, for å finne mulige årsaker.

Aftenposten 20. oktober 1993

19

- Hvordan kan vi forklare at krefttilfellene i Sømna skyldes en ren tilfeldighet?
- Må da være oppmerksom på hvorfor krefttilfellene i Sømna vakte oppsikt
- Det skjedde nettopp fordi det ble registrert uvanlig mange krefttilfeller i denne ene kommunen i dette ene året
- Alle de kommunene og alle de årene der det ikke skjer noe oppsiktsekkende, er det ingen som bryr seg om

20

- Vi må derfor spørre: Hva er sannsynligheten for at vi en gang i blant i en eller annen kommune vil observere noe så påfallende som det en gjorde i Sømna i 1992 ved en ren tilfeldighet?
- Regneeksempel: Vi tenker oss at vi har 100 kommuner med samme størrelse og befolkningsstruktur som Sømna, og at vi observerer antall krefttilfeller i disse kommunene i en tiårs periode.
- Sannsynligheten for at vi i minst én av kommunene vil oppleve minst tre tilfeller av hjernesvulst i løpet av ett år ved en ren tilfeldighet er:

$$1 - (1 - 0.0006)^{1000} = 0.45$$

- Det er sannsynlig at noe så usannsynlig som det som skjedde i Sømna vil skje en gang i blant ved en ren tilfeldighet